# Meta-análisis de correlaciones en R Guía básica

Juan David Leongómez<sup>1</sup>

02 noviembre, 2021

<sup>1</sup> Laboratorio de Análisis del Comportamiento Humano (LACH), Facultad de Psicología, Universidad El Bosque, Bogotá, Colombia. Email: jleongomez@unbosque.edu.co. Web: jdleongomez.info.

### Descripción

Este documento contiene todo el código explicaciones básicas, paso a paso, para hacer un meta-análisis en R, usando los paquetes metafor (Viechtbauer, 2010) y robumeta (Fisher & Tipton, 2015). Está principalmente basado en este video, creado por Daniel S. Quintana (2021), pero contiene citas a fuentes primarias, además de información que he agregado.

# Índice

Referencias

L. ]	Met	a-análisis de correlación
-	1.1.	Base de datos de ejemplo
-	1.2.	Transformación de $r$ de Pearson a $z$ de Fisher
-	1.3.	Hacer el meta-análisis
		1.3.1. Más información sobre heterogeneidad
		1.3.2. Diagnóstico de influencia
		1.3.3. Forest plot (diagrama de bosque)
		1.3.4. Funnel plot (diagrama de embudo) y sesgo de estudios pequeños
		1.3.4.1. Funnel plot
		1.3.4.2. Regresión de Egger
-	1.4.	Meta-análisis de correlación con moderador
		1.4.1. Ejemplo 1: Moderación de la edad promedio de los participantes
		1.4.1.1. Forest plot y funnel plot
		1.4.2. Ejemplo 2: Moderación de la calidad de los estudios meta-analizados
		1.4.3. Ejemplo 3: Moderación de las controles usados en cada estudio meta-analizado
	1.5.	Sesgo de publicación (publication bias)

## 1. Meta-análisis de correlación

## 1.1. Base de datos de ejemplo

La base de datos dat.molloy2014, tomada de Molloy et al. (2013) viene incluída con {metafor}. Básicamente, estudia si existe una asociación entre la diligencia (conscientiousness) y la adherencia a la medicación. En otras palabras, ¿las personas más diligentes son más propensas a cumplir con la medicación prescrita?

18

La base da datos, que he asignado a un objeto llamado dat, tiene ahora la siguiente estructura (Tabla 1):

Tabla 1

Estructura de la base de datos

$study\_id$	authors	year	ni	ri	controls	design	$a\_measure$	$c\_measure$	meanage	quality
1	Axelsson et al.	2009	109	0.187	none	cross-sectional	self-report	other	22.00	1
2	Axelsson et al.	2011	749	0.162	none	cross-sectional	self-report	NEO	53.59	1
3	Bruce et al.	2010	55	0.340	none	prospective	other	NEO	43.36	2
4	Christensen et al.	1999	107	0.320	none	cross-sectional	self-report	other	41.70	1
5	Christensen & Smith	1995	72	0.270	none	prospective	other	NEO	46.39	2
6	Cohen et al.	2004	65	0.000	none	prospective	other	NEO	41.20	2
7	Dobbels et al.	2005	174	0.175	none	cross-sectional	self-report	NEO	52.30	1
8	Ediger et al.	2007	326	0.050	$\operatorname{multiple}$	prospective	self-report	NEO	41.00	3
9	Insel et al.	2006	58	0.260	none	prospective	other	other	77.00	2
10	Jerant et al.	2011	771	0.010	$\operatorname{multiple}$	prospective	other	NEO	78.60	3
11	Moran et al.	1997	56	-0.090	$_{ m multiple}$	prospective	other	NEO	57.20	2
12	O'Cleirigh et al.	2007	91	0.370	none	prospective	self-report	NEO	37.90	2
13	Penedo et al.	2003	116	0.000	none	cross-sectional	self-report	NEO	39.20	1
14	Quine et al.	2012	537	0.150	none	prospective	self-report	other	69.00	2
15	Stilley et al.	2004	158	0.240	none	prospective	other	NEO	46.20	3
16	Wiebe & Christensen	1997	65	0.040	none	prospective	other	NEO	56.00	1

Nota: Datos tomados de Molloy et al. (2013).

La columna ri contiene los coeficientes de correlación de Pearson (la columna ni contiene los tamaños de muestra de cada estudio). Dado que los coeficientes de Pearson no tienen una distribución normal, esto podría llevar a calcular varianzas incorrectas, especialmente cuando se trata de correlaciones con tamaños de muestra pequeños.

Adicionalmente, en este ejemplo tenemos una serie de moderadores:

- controls: número de variables controladas
- design: si se utilizó un diseño transversal o prospectivo
- a\_measure: tipo de medida de adherencia (autoinforme u otro)
- c\_measure: tipo de medida de diligencia (NEO u otra)
- meanage: edad promedio de la muestra
- quality: calidad metodológica

## 1.2. Transformación de r de Pearson a z de Fisher

Por esto, vamos a transformar los coeficientes r de Pearson a z de Fisher, que no tienen este problema. Para esto, vamos a usar la función escalc del paquete metafor.

Esto ha creado dos nuevas variables en nuestra tabla: yi, que es el tamaño de efecto, y vi que es la varianza.

Tabla 2

Estructura de la base de datos, con transformación de los r de Pearon a z de Fisher

study_id	authors	year	ni	ri	controls	design	a_measure	$c\_measure$	meanage	quality	yi	vi
1	Axelsson et al.	2009	109	0.187	none	cross-sectional	self-report	other	22.00	1	0.1892266	0.0094340
2	Axelsson et al.	2011	749	0.162	none	cross-sectional	self-report	NEO	53.59	1	0.1634399	0.0013405
3	Bruce et al.	2010	55	0.340	none	prospective	other	NEO	43.36	2	0.3540925	0.0192308
4	Christensen et al.	1999	107	0.320	none	cross-sectional	self-report	other	41.70	1	0.3316471	0.0096154
5	Christensen & Smith	1995	72	0.270	none	prospective	other	NEO	46.39	2	0.2768638	0.0144928
6	Cohen et al.	2004	65	0.000	none	prospective	other	NEO	41.20	2	0.0000000	0.0161290
7	Dobbels et al.	2005	174	0.175	none	cross-sectional	self-report	NEO	52.30	1	0.1768200	0.0058480
8	Ediger et al.	2007	326	0.050	multiple	prospective	self-report	NEO	41.00	3	0.0500417	0.0030960
9	Insel et al.	2006	58	0.260	none	prospective	other	other	77.00	2	0.2661084	0.0181818
10	Jerant et al.	2011	771	0.010	multiple	prospective	other	NEO	78.60	3	0.0100003	0.0013021
11	Moran et al.	1997	56	-0.090	multiple	prospective	other	NEO	57.20	2	-0.0902442	0.0188679
12	O'Cleirigh et al.	2007	91	0.370	none	prospective	self-report	NEO	37.90	2	0.3884231	0.0113636
13	Penedo et al.	2003	116	0.000	none	cross-sectional	self-report	NEO	39.20	1	0.0000000	0.0088496
14	Quine et al.	2012	537	0.150	none	prospective	self-report	other	69.00	2	0.1511404	0.0018727
15	Stilley et al.	2004	158	0.240	none	prospective	other	NEO	46.20	3	0.2447741	0.0064516
16	Wiebe & Christensen	1997	65	0.040	none	prospective	other	NEO	56.00	1	0.0400214	0.0161290

Nota: Datos tomados de Molloy et al., (2013).

#### 1.3. Hacer el meta-análisis

Para hacer el meta-análisis, usaremos la función rma del paquete metafor, para el que tenemos que especificar los tamaños de efecto (yi) y varianzas (vi) de los estudios a meta-analizar. En este caso, las columnas donde tenemos estos valores, tienen los mismos nombres (yi, vi). Asignaré los resultados del meta-análisis a un objeto llamado res.

```
res <- rma(yi = yi, vi = vi, data = dat)
```

Los resultados, son los siguientes:

```
res
```

```
## Random-Effects Model (k = 16; tau^2 estimator: REML)
##
## tau^2 (estimated amount of total heterogeneity): 0.0081 (SE = 0.0055)
## tau (square root of estimated tau^2 value):
                                                     0.0901
  I^2 (total heterogeneity / total variability):
                                                     61.73%
## H^2 (total variability / sampling variability):
##
## Test for Heterogeneity:
## Q(df = 15) = 38.1595, p-val = 0.0009
##
## Model Results:
##
##
  estimate
                 se
                       zval
                               pval
                                      ci.lb
                                               ci.ub
##
            0.0316
                    4.7501
                             <.0001
                                     0.0881
                                             0.2118
##
##
## Signif. codes: 0 '*** 0.001 '** 0.01 '* 0.05 '.' 0.1 ' 1
```

Primero, nos confirma que ajustamos un modelo con efectos aleatorios (Random-Effects Model), a partir de 16 estudios (k = 16), y que para estimar  $\tau^2$  (tau cuadrado<sup>1</sup>) usamos el método de **máxima verosimilitud restringida**<sup>2</sup> (tau^2 estimator: REML), que se designa como REML por sus siglas en inglés.

Posteriormente, nos provee los valores de una serie de estimadores de heterogeneidad o varianza:

 $<sup>^{1}\</sup>tau^{2}$  es una estimación de la varianza de los tamaños de los efectos reales entre los estudios meta-analizados. Se usa, principalmente, para asignar pesos a cada estudio. Para más información, ver (Borenstein et al., 2009).

<sup>&</sup>lt;sup>2</sup>Hay varios métodos disponibles como estimador, además de **máxima verosimilitud restringida** (REML). Sin embargo, si no estás seguro, REML es una buena opción. Cada método tiene ventajas y desventajas que, si tienes interés en mirar, están descritas en la documentación de la función rma.

```
\bullet \tau^2: tau^2 (estimated amount of total heterogeneity): 0.0081 (SE = 0.0055)
```

- ullet au: tau (square root of estimated tau^2 value): 0.0901
- $I^2$ : I^2 (total heterogeneity / total variability): 61.73%, y
- $H^2$ : H<sup>2</sup> (total variability / sampling variability): 2.61

La tercera parte, reporta una prueba de heterogeneidad, usando el estadístico Q:

■ Test for Heterogeneity:

```
Q(df = 15) = 38.1595, p-val = 0.0009
```

De todos estos, los más comúnmente reportados son  $\tau^2$ ,  $\tau$ ,  $I^2$  y Q. Cada una de estas medidas tiene ventajas y desventajas, por lo cual tiene sentido reportarlas todas.

 $I^2$ , por ejemplo, tiene la ventaja de ser sencillo de interpretar, pues hay criterios generales para heterogeneidad baja, moderada y alta (típicamente 25%, 50%, and 75%, respectivamente). Sin embargo, es muy sensible a los tamaños de muestra de los estudios meta-analizados (por ejemplo, si en tu meta-análisis hay estudios con tamaños de muestra muy grandes, esto va a sesgar tu  $I^2$ ).

Q, aunque no es sensible al tamaño de muestra, es sensible al número de estudios meta-analizados. Tiene la ventaja de ser un test de hipótesis, y como tal, puede ser interpretado a partir de su valor p.

 $\tau^2$  no tiene estos problemas, pero es más difícil de interpretar.

En nuestro caso, el estadístico Q sugiere que hay una heterogeneidad significativa en los estudios meta-analizados (p=0.0009).  $I^2$ , sugiere una heterogeneidad moderada, lo que quiere decir que más de la mitad (61.73%) de la varianza se estima que se deriva de diferencias en los tamaños de efecto.

Por último, tenemos los resultados del modelo de meta-análisis (Model results). Nos provee un estimado de la asociación positiva entre diligencia y adherencia a la medicación (0.1499  $\pm$  0.0316), lo que equivale a un valor z de 4.7501, y sugiere que esa asociación es significativa (p < .0001). Así mismo, nos provee los límites inferior (0.0881) y superior (0.2118) de los intervalos de confianza.

### 1.3.1. Más información sobre heterogeneidad

Además de reportar los estadísticos  $\tau^2$ ,  $\tau$ ,  $I^2$  y Q, podemos fácilmente calcular los intervalos de confianza para  $\tau^2$ ,  $\tau$ , e  $I^2$  con la función **confint**, que también pueden ser reportado junto a estos estadísticos.

#### confint(res)

```
##
##
          estimate
                      ci.lb
                              ci.ub
## tau^2
            0.0081
                     0.0017
                             0.0378
## tau
            0.0901
                     0.0412
                             0.1944
## I^2(%)
           61.7324 25.2799 88.2545
## H^2
            2.6132
                    1.3383
```

Para el  $\tau^2$ , el hecho de que los intervalos de confianza no crucen el 0 (en nuestro caso 0.0017 — 0.0378), sugiere que de hecho también que hay heterogeneidad entre los estudios que meta-analizamos.

#### 1.3.2. Diagnóstico de influencia

Otro aspecto importante de un meta-análisis, es determinar si alguno(s) de los estudios meta-analizados es(son) particularmente influyente(s) en nuestro resultado<sup>3</sup>. Para esto, podemos usar la función **influence**, cuyo resultado en este caso asignaré a un objeto llamado **inf**.

#### inf <- influence(res)</pre>

Ya que lo asigné a un objeto (inf), para ver el resultado, tengo que correrlo para ver su resultado.

 $<sup>^3</sup>$ Por ejemplo, si estuviésemos meta-analizando 20 estudios, de los cuales 19 tienen un n de 100, pero el otro tiene un n de 10.000, éste último tendrá una influencia enorme en nuestro resultado. Sería preocupante que tu meta-análisis sea dependiente de un único estudio.

```
inf
##
##
                              rstudent
                                        dffits cook.d cov.r tau2.del QE.del
## Axelsson et al., 2009
                                0.2918
                                        0.0485 0.0025 1.1331
                                                                0.0091 37.7109
                                0.1196 -0.0031 0.0000 1.2595
## Axelsson et al., 2011
                                                                0.0100 36.7672
## Bruce et al., 2010
                                1.2740
                                        0.2595 0.0660 0.9942
                                                                0.0075 35.3930
   Christensen et al., 1999
                                1.4711
                                        0.3946 0.1439 0.9544
                                                                0.0068 33.5886
                                        0.1838 0.0339 1.0505
   Christensen & Smith, 1995
                                0.8622
                                                                0.0082 36.5396
## Cohen et al., 2004
                               -0.9795 -0.2121 0.0455 1.0639
                                                                0.0084 37.1703
## Dobbels et al., 2005
                                0.2177
                                        0.0296 0.0010 1.1740
                                                                0.0094 37.6797
## Ediger et al., 2007
                               -0.9774 -0.3120 0.1001 1.1215
                                                                0.0084 36.1484
## Insel et al., 2006
                                0.7264
                                        0.1392 0.0195 1.0561
                                                                0.0083 37.0495
## Jerant et al., 2011
                               -1.8667 -0.5861 0.2198 0.8502
                                                                0.0047 25.0661
## Moran et al., 1997
                               -1.4985 -0.2771 0.0756 1.0073
                                                                0.0077 35.6617
## O'Cleirigh et al., 2007
                                1.8776
                                        0.4918 0.2148 0.8819
                                                                0.0059 31.9021
## Penedo et al., 2003
                               -1.1892 -0.2939 0.0859 1.0550
                                                                0.0080 36.3291
## Quine et al., 2012
                               -0.0020 -0.0423 0.0021 1.2524
                                                                0.0100 37.7339
## Stilley et al., 2004
                                0.8066 0.2126 0.0459 1.0907
                                                                0.0083 35.8385
  Wiebe & Christensen, 1997
                               -0.7160 -0.1656 0.0280 1.0853
                                                                0.0087 37.7017
##
                                 hat
                                      weight
                                                dfbs inf
## Axelsson et al., 2009
                              0.0568
                                      5.6776
                                              0.0481
## Axelsson et al., 2011
                              0.1054 10.5396 -0.0032
## Bruce et al., 2010
                              0.0364
                                      3.6432
                                              0.2623
   Christensen et al., 1999
                              0.0562
                                      5.6195
                                              0.3994
   Christensen & Smith, 1995 0.0441
                                      4.4069
                                              0.1837
   Cohen et al., 2004
                              0.0411
                                      4.1094 -0.2112
                                      7.1362
## Dobbels et al., 2005
                              0.0714
                                              0.0296
## Ediger et al., 2007
                              0.0889
                                      8.8886 -0.3128
## Insel et al., 2006
                                      3.7886
                                              0.1387
                              0.0379
## Jerant et al., 2011
                              0.1058 10.5826 -0.5430
## Moran et al., 1997
                              0.0369
                                      3.6922 -0.2791
## O'Cleirigh et al., 2007
                              0.0511
                                      5.1150
                                              0.5059
## Penedo et al., 2003
                              0.0587
                                      5.8732 -0.2941
## Quine et al., 2012
                              0.0998
                                      9.9778 -0.0434
## Stilley et al., 2004
                              0.0684
                                      6.8403
                                             0.2125
## Wiebe & Christensen, 1997 0.0411
                                      4.1094 -0.1642
```

Esto me muestra gran cantidad de información de cada estudio (en este caso, una tabla sin formato, que es muy ancha para poder imprimirse en esta página, por lo cual está reportada en dos partes). Sin embargo, lo más importante ahora es mirar la última columna, también llamada inf. Si ahí aparecieran asteriscos (que no es nuestro caso), sugeriría que ese estudio es particularmente influyente.

Por último, podemos también ver ésta información que tenemos guardada en el objeto inf, de manera gráfica, usando la función plot.

#### plot(inf)




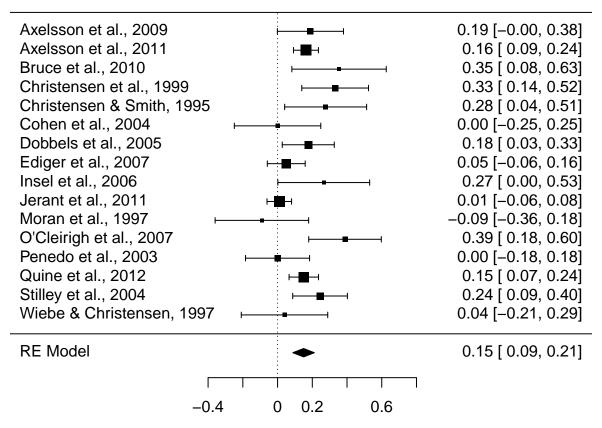
Figura 1. Diagnóstico de influencia. Estudios particularmente influyentes serpian representados con un punto rojo. En este caso, no hay ningún estudio que se considere demasiado influyente, por lo que podemos estar tranquilos con nuestro meta-análisis.

#### 1.3.3. Forest plot (diagrama de bosque)

Para hacer un diagrama de bosque (forest plot) con metafor resumiendo nuestro meta-análisis, solo tenemos que usar la función forest, usando como argumento el objeto al que asignamos los resultados de nuestro meta-análisis (res).

Como se puede ver en las Figuras 2, 3 y 4 (que son 3 versiones del mismo forest plot), no es una sorpresa que el análisis nos sugiera bastante heterogeneidad; las correlaciones encontradas entre los diferentes estudios varían mucho (están entre -0.09 y 0.37), y aunque son positivas en la mayoría de los casos (en algunos claramente positivas), en algunos son prácticamente 0 o incluso negativas.

forest(res)



Fisher's z Transformed Correlation Coefficient

Figura~2.~Forest~plot~ básico de metafor. Para cada estudio meta-analizado, tenemos el efecto (correlación, en este caso en valores z de Fisher), así como sus intervalos de confianza entre paréntesis cuadrados. Esta misma información está representada gráficamente, con los cuadrados representando el efecto de cada estudio así como sus intervalos de confianza, y el tamaño de muestra (representado por el tamaño del cuadrado). Bajo estos resultados, tenemos nuestro meta-análisis, con el mismo formato en texto, pero representando el efecto y sus intervalos de confianza con un diamante.

Para una versión más completa y anotada, también usando el *plot* básico de metafor, pero representando coeficientes de correlación de Pearson (r) en vez de valores z, así como agregando una columna con los pesos dados a cada estudio, y detalles del modelo final, podemos agregar algunas opciones (explicadas aca):

```
text(x = -1.6, y = 18, labels = "Autor(es), Año", pos = 4)
text(x = 0, y = 18, labels = "Efecto e IC", pos = 4)
text(x = 1, y = 18, labels = "Peso", pos = 2)
text(x = 1.6, y = 18, labels = "Corr. [95% IC]", pos = 2)
```




Figura 3. Forest plot anotado, creado con metafor. En esta versión agregué algunos encabezados en español, así como estadísticos generales del modelo de meta-análisis. Modelo EA se refiere al modelo meta-analizado, de efectos aleatorios.

O, para una incluso más sofisticada, se puede usar la función viz\_forest del paquete metaviz, en este caso usando la variante rain (no es necesaria).




Figura 4. Forest plot creado con metaviz.

### 1.3.4. Funnel plot (diagrama de embudo) y sesgo de estudios pequeños

En este punto, es en donde más errores se cometen. Las pruebas más comunes para evaluar sesgos de publicación, son la evaluación de la asimatría en el *funnel plot* (diagrama de embudo), y la regresión (o test) de Egger (Egger et al., 1997).

El principal error que la mayoría de los investigadores (meta-analistas) cometen, es que simplemente basándose en éstos métodos, concluyen que un meta-análisis tiene (o no) riesgo de sufrir de un sesgo de publicación. Sin embargo, estos métodos, no son pruebas exclusivas de sesgo de publicación, sino de sesgo de estudios de tamaño muestral pequeño (ver e.g. Schwarzer et al., 2015), que pueden incluir sesgo de publicación, pero no se centran exclusivamente en éste.

A pesar de esto, tanto la regresión de Egger como el funnel plot, son intersantes dado que el sesgo de estudios pequeños es importante.

**1.3.4.1.** Funnel plot Para crear un funnel plot con metafor, de nuestro meta-análisis, solo tenemos que usar la función funnel, usando como argumento el objeto al que asignamos los resultados de nuestro meta-análisis (res).

funnel(res)




Figura 5. Funnel plot básico de metafor. Para cada estudio meta-analizado, tenemos el efecto (correlación, en este caso en valores z de Fisher) en el eje X, así como su error estándar en el eje Y. La línea punteada vertical representa el efecto meta-analizado que hemos encontrado, así que podemos ver los estudios que encontraron un efecto mayor (derecha de la línea punteada) o menor (izquierda) de éste. A primera vista no parece haber mucha asimetría, pero es importante tener en cuenta que es un análisis muy subjetivo.

De nuevo, se puede usar el paquete metaviz, usando la función  $viz\_funnel$ . Hay muchas opciones, pero como ejemplo, usaré la versión por defecto, agregando solo la línea de la regressión de Egger (egger = TRUE; ver sección 1.3.4.2, a continuación), y transformando los tamaños de efecto de regreso a r de Pearson ( $x\_trans\_function = tanh$ ).




Figura 6. Funnel plot creado con metaviz. En azul, se representa el área donde estudios, segpun su error (y su tamaño de muestra), tendrían un efecto significativo al 5% (i.e. p > 0.05), y fuera de ésta, donde tendrían un efecto significativo al 1% (i.e. p > 0.01). La línea negra vertical representa el efecto meta-analizado, y el triángulo a partir de su inicio, el área donde se ubican los estudios que no se diferencian significativamente del resultado del meta-análisis. La línea roja punteada, representa la regresión de Egger.

Alternativamente, el paquete  $\mathtt{metaviz}$  tiene la función  $\mathtt{viz\_sunset}$ , que permite además mostrar el poder estadístico (o potencia) de los estudios meta-analizados para detectar un efecto de interés mediante una prueba de Wald de dos colas. A continuación, muestro dos versiones de esta función. En ambos casos, agregué el efecto  $\mathit{real}$  encontrado con el meta-análisis (contours = TRUE), y transformé los tamaños de efecto de regreso a  $\mathit{r}$  de Pearson (x\_trans\_function = tanh).




Figura 7. Dos versiones de funnel plot creados con metaviz, usando la función viz-sunset, que estima el poder de cada estudio para detectar un efecto de interés. A. Poder representado por bandas dicretas de color. B. Poder representado de manera contpinua en una escala de color. En ambos casos, y tal como en la Fig. 6, el efecto real está representado como una línea vertical, y el triángulo a partir de su inicio representa el área donde se ubican los estudios que no se diferencian significativamente del resultado del meta-análisis.

1.3.4.2. Regresión de Egger Para hacer una prueba formal de sesgo de estudios pequeños, podemos hacer una prueba o regresión de Egger (Egger et al., 1997). En metafor, esto se hace con la función regtest, de nuevo usando como argumento el objeto al que asignamos el resultado de nuestro meta-análisis (res).

```
regtest(res)
```

Como se puede ver, la prueba de Egger no muestra un resultado significativo (z = 1.0216, p = 0.3070).

Con base en esto, y la inspección visual subjetiva del *funnel plot*, muchos investigadores concluyen que no hay sesgo de publicación. Sin embargo, como mencioné antes, estas pruebas no se centran en el sesgo de publicación sino en el sesgo de estudios pequeños. En otras palabras, con base en esto, lo único que podemos concluir correctamente, es que no hay sesgo de estudios pequeños (más adelante, en la sección XXXXX, explicaré cómo evaluar si hay sesgo de publicación).

#### 1.4. Meta-análisis de correlación con moderador

#### 1.4.1. Ejemplo 1: Moderación de la edad promedio de los participantes

Primero, y como ejemplo, vamos a ver si la edad (en nuestros datos, meanage) modera el resultado. Esto es importante, pues hay una enorme variación entre las edades medias de los participantes de los diferentes estudios<sup>4</sup>, lo que podría moderar (afectar) la asociación entre diligencia (conscientiousness) y adherencia a la medicación prescrita.

Para esto, de nuevo podemos usar la función rma de paquete metafor y de la misma manera que en la sección 1.3, pero agregando nuestra variable moderadora (meanage) al argumento mods. En este caso voy a asignar a un objeto llamado res.modage, para diferenciarlo del objeto res al que asigné el meta-análisis básico, sin moderadores.

```
res.modage <- rma(yi = yi, vi = vi, mods = ~meanage, data = dat)
```

Los resultados, son los siguientes:

#### res.modage

```
##
## Mixed-Effects Model (k = 16; tau^2 estimator: REML)
##
## tau^2 (estimated amount of residual heterogeneity):
                                                             0.0072 \text{ (SE = } 0.0054)
                                                             0.0846
## tau (square root of estimated tau^2 value):
## I^2 (residual heterogeneity / unaccounted variability): 56.50%
## H^2 (unaccounted variability / sampling variability):
                                                             2.30
## R^2 (amount of heterogeneity accounted for):
                                                             11.76%
##
  Test for Residual Heterogeneity:
  QE(df = 14) = 30.9050, p-val = 0.0057
##
## Test of Moderators (coefficient 2):
## QM(df = 1) = 1.4286, p-val = 0.2320
##
## Model Results:
##
##
            estimate
                                                   ci.lb
                                                           ci.ub
                           se
                                  zval
                                          pval
                      0.1090
                                2.5147
                                        0.0119
                                                  0.0605
                                                          0.4877
## intrcpt
              0.2741
             -0.0024
                      0.0020
                              -1.1952
                                        0.2320
                                                -0.0063
                                                          0.0015
## meanage
##
##
## Signif. codes:
                   0 '*** 0.001 '** 0.01 '* 0.05 '. ' 0.1 ' 1
```


Los resultados, que tienen la misma organización que los del análisis sin moderadores (sección 1.3) resultado nos muestra que, a pesar de la gran diferencia de edad entre estudios, la edad no tiene un efecto significativo, como se puede ver en la columna pval para el efecto de meanage (0.232).

<sup>&</sup>lt;sup>4</sup>De hecho, mientras que en el estudio de Axelsson et al. (2009) la edad promedio fue de 22, en el estudio de Jerant et al. (2011) la edad promedio fue de 78.6.

**1.4.1.1.** Forest plot y funnel plot Por supuesto, de estos resultados también puedo crear forest plots y funnel plots, siguiendo los ejemplos y código de la sección 1.3.

Para el forest plot, hago a continuación un ejemplo usando la opción básica (por supuesto, se pueden crear versiones anotadas y mejoradas, pero la función viz\_forest del paquete metaviz tendrá problemas para crear un forest plot de un meta-análisis con moderadores).

```
# forest plot con anotaciones adicionales
forest(res.modage, xlim = c(-1.6, 1.6))
text(-1.6, 18, "Autor(es), Año", pos = 4)
text(1.6, 18, "Correlación [95% CI]", pos = 2)
```



Fisher's z Transformed Correlation Coefficient

Figura 8. Forest plot básico de metafor, para un meta-análisis incluyendo la edad promedio de los participantes como moderador. En la ilustración gráfica, además de los efectos originales, se puede ver el efecto de cada estudio estimado cuando se incluye el moderador como polígonos (diamantes) de color gris. Sin embargo, ya no obtenemos una fila representando el efecto promediado del meta-análisis, ya que no tenemos un solo efecto.

De manera similar, podemos obtener un funnel plot de nuestro meta-análisis con moderador, pero éste nos mostrará, en vez de los coeficientes de correlación (transformados a z de Fisher), los valores residuales de cada estudio (es decir, qué tanto se alejan del resultado de nuestro meta-análisis):




Figura 9. Funnel plot básico de metafor, para un meta-análisis incluyendo la edad promedio de los participantes como moderador. La línea punteada vertical representa el efecto meta-analizado que hemos encontrado, así que podemos ver los estudios que encontraron un efecto mayor (derecha de la línea punteada) o menor (izquierda) de éste.

## 1.4.2. Ejemplo 2: Moderación de la calidad de los estudios meta-analizados

La base de datos con tiene una medida de calidad metodológica de los estudios (variable quality). Dicha calidad, también podría moderar la asociación entre diligencia (conscientiousness) y adherencia a la medicación prescrita. Siguiendo los mismos pasos, puedo hacer éste análisis, pero voy a asignar este meta-análisis a un objeto llamado res.modq para diferenciarlo de los demás.

```
res.modq <- rma(yi = yi, vi = vi, mods = ~quality, data = dat)
res.modq

##
## Mixed-Effects Model (k = 16; tau^2 estimator: REML)
##
## tau^2 (estimated amount of residual heterogeneity): 0.0078 (SE = 0.0057)
## tau (square root of estimated tau^2 value): 0.0884
## I^2 (residual heterogeneity / unaccounted variability): 57.79%</pre>
```

```
## H^2 (unaccounted variability / sampling variability):
                                                             2.37
## R^2 (amount of heterogeneity accounted for):
                                                             3.73%
##
## Test for Residual Heterogeneity:
##
  QE(df = 14) = 30.4205, p-val = 0.0067
##
## Test of Moderators (coefficient 2):
##
  QM(df = 1) = 0.6393, p-val = 0.4240
##
## Model Results:
##
##
            estimate
                           se
                                  zval
                                          pval
                                                  ci.lb
                                                           ci.ub
                                        0.0089
## intrcpt
              0.2082 0.0796
                                2.6149
                                                 0.0521
                                                          0.3643
                               -0.7995
                                        0.4240
  quality
             -0.0312
                      0.0391
                                                -0.1078
##
##
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

De nuevo, encontramos que éste moderador (quality), al igual que la edad promedio (meanage), no tiene un efecto significativo, como se puede ver en la columna pval para el efecto de quality (0.424).

Por supuesto, forest plots y funnel plots pueden ser creados, tal y como describí en la sección 1.4.1.1.

#### 1.4.3. Ejemplo 3: Moderación de las controles usados en cada estudio meta-analizado

Como último ejemplo, voy a mirar si el hecho de que los estudios tengan variables que fueron controladas, modera la asociación entre diligencia (conscientiousness) y adherencia a la medicación prescrita. Siguiendo los mismos pasos, voy hacer éste análisis, pero voy a asignar este meta-análisis a un objeto llamado res.mes. Son embargo, dado que la variable que contiene esta información (controls) es un factor, pero no está definido como tal, debo hacerlo en la usando la función factor al ingresar el argumento mods (i.e. mods = ~factor(controls)).

```
res.mes <- rma(yi = yi, vi = vi, mods = ~factor(controls), data = dat)
res.mes
```

```
## Mixed-Effects Model (k = 16; tau^2 estimator: REML)
##
                                                             0.0000 \text{ (SE = } 0.0015)
## tau^2 (estimated amount of residual heterogeneity):
  tau (square root of estimated tau^2 value):
                                                              0.0002
## I^2 (residual heterogeneity / unaccounted variability): 0.00%
## H^2 (unaccounted variability / sampling variability):
                                                              1.00
## R^2 (amount of heterogeneity accounted for):
                                                              100.00%
##
## Test for Residual Heterogeneity:
## QE(df = 14) = 18.0370, p-val = 0.2051
##
## Test of Moderators (coefficient 2):
## QM(df = 1) = 20.1221, p-val < .0001
##
## Model Results:
##
##
                          estimate
                                        se
                                               zval
                                                       pval
                                                               ci.lb
                                                                        ci.ub
## intrcpt
                            0.0167
                                    0.0296
                                            0.5635
                                                     0.5731
                                                             -0.0413
                                                                       0.0746
## factor(controls)none
                            0.1621
                                    0.0361
                                            4.4858
                                                     <.0001
                                                               0.0913
                                                                      0.2329
##
##
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

En éste caso, a diferencia de los ejemplos de moderación anteriores, la variable moderadora (controls) sí tiene un

efecto significativo, como se puede ver en la columna pval para el efecto de factor(controls)none (<0.001), y en los asteriscos que aparecen al final de esa fila (\*\*\*).

Por supuesto, forest plots y funnel plots pueden ser creados, tal y como describí en la sección 1.4.1.1.

## 1.5. Sesgo de publicación (publication bias)

```
library(weightr)
## Loading required package: scales
## Attaching package: 'weightr'
## The following objects are masked from 'package:metafor':
##
##
       dat.bangertdrowns2004, funnel
## The following object is masked from 'package:stats':
##
##
       density
wf <- weightfunct(effect = dat$yi, v = dat$vi, table = TRUE)</pre>
##
## Unadjusted Model (k = 16):
## tau^2 (estimated amount of total heterogeneity): 0.0070 (SE = 0.0051)
  tau (square root of estimated tau^2 value): 0.0834
##
## Test for Heterogeneity:
## Q(df = 15) = 38.1595, p-val = 0.001436053
##
## Model Results:
##
##
             estimate std.error z-stat
                                            p-val
                                                    ci.lb ci.ub
                        0.03073 4.835 1.3288e-06 0.08837 0.2088
##
  Intercept
               0.1486
##
## Adjusted Model (k = 16):
##
## tau^2 (estimated amount of total heterogeneity): 0.0056 (SE = 0.0045)
## tau (square root of estimated tau^2 value): 0.0750
##
## Test for Heterogeneity:
## Q(df = 15) = 38.1595, p-val = 0.001436053
##
## Model Results:
##
##
                 estimate std.error z-stat
                                                        ci.lb ci.ub
                                              p-val
                  0.09153
                            0.04464 2.050 0.040341 0.00403 0.1790
## Intercept
## 0.025 
                            0.20122 1.199 0.230626 -0.15317 0.6356
##
## Likelihood Ratio Test:
## X^2(df = 1) = 2.98493, p-val = 0.084043
##
## Number of Effect Sizes per Interval:
##
##
                        Frequency
```

## p-values <0.025 9 ## 0.025 < p-values < 1 7

## Referencias

Borenstein, M., Hedges, L. V., Higgns, J. P. T., & Rothstein, H. R. (2009). Identifying and Quantifying Heterogeneity. In *Introduction to Meta-Analysis* (pp. 107–125). Wiley. https://doi.org/10.1002/9780470743386.ch16

Egger, M., Smith, G. D., Schneider, M., & Minder, C. (1997). Bias in meta-analysis detected by a simple, graphical test. *BMJ*, 315(7109), 629–634. https://doi.org/10.1136/bmj.315.7109.629

Fisher, Z., & Tipton, E. (2015). Robumeta: An R-package for robust variance estimation in meta-analysis. arX-iv:1503.02220 [Stat]. https://arxiv.org/abs/1503.02220

Molloy, G. J., O'Carroll, R. E., & Ferguson, E. (2013). Conscientiousness and Medication Adherence: A Meta-analysis. *Annals of Behavioral Medicine*, 47(1), 92–101. https://doi.org/10.1007/s12160-013-9524-4

Quintana, D. S. (2021). How to perform a meta-analysis in R. [Archivo de Vídeo]. YouTube. https://youtu.be/lH4VZMTEZSc.

Schwarzer, G., Carpenter, J. R., & Rücker, G. (2015). Small-Study Effects in Meta-Analysis. In G. Schwarzer, J. R. Carpenter, & G. Rücker (Eds.), *Meta-Analysis with R* (pp. 107–141). Springer International Publishing. https://doi.org/10.1007/978-3-319-21416-0\_5

Viechtbauer, W. (2010). Conducting Meta-Analyses inRwith themetaforPackage. *Journal of Statistical Software*, 36(3). https://doi.org/10.18637/jss.v036.i03